LAPORAN UTS
COMPUTER VISION



KELOMPOK 14

OKSAVIYANA ALFAREZI	**187221097**
DZAKY MUTTAQI SUNARYADI	**187231075**
RADITYA NAUVAL RAMADHAN	**187231077**
DIMAS AKBAR HATAPUTRA	**187231088**
AMIR GYMNASTIAR	**187231093**

PROGRAM STUDI SARJANA SISTEM INFORMASI

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS AIRLANGGA SURABAYA

2026

BAB I
PENDAHULUAN

1.1 Latar Belakang

Pengolahan citra digital merupakan salah satu bidang *computer vision* yang dapat digunakan untuk mengolah dan menganalisis informasi visual dari suatu gambar. Salah satu penerapannya adalah pengenalan motif batik berdasarkan karakteristik visualnya. Motif batik memiliki variasi pola dan bentuk yang dapat menjadi pembeda antara satu jenis motif dengan jenis lainnya.

Pada praktikum Ujian Tengah Semester (UTS) ini, pengolahan citra dilakukan menggunakan dataset *Indonesian Batik Motifs* dari Kaggle. Dataset yang digunakan dibatasi pada lima kelas motif batik, yaitu Ceplok, Kawung, Megamendung, Parang, dan Tambal. Tahapan pengolahan meliputi konversi citra menjadi *grayscale*, peningkatan kualitas citra menggunakan metode *Histogram Equalization*, *Contrast Stretching*, dan *Contrast Limited Adaptive Histogram Equalization* (CLAHE), serta penerapan *median filtering* untuk mengurangi gangguan pada citra.

Kualitas hasil pengolahan dievaluasi menggunakan *Mean Squared Error* (MSE) dan *Peak Signal-to-Noise Ratio* (PSNR). Selanjutnya, dilakukan ekstraksi fitur menggunakan *Local Binary Pattern* (LBP) dan *Scale-Invariant Feature Transform* (SIFT) dengan pendekatan *Bag of Visual Words* (BoVW). Fitur yang diperoleh kemudian digunakan dalam klasifikasi menggunakan *Support Vector Machine* (SVM) untuk membandingkan kinerja kedua pendekatan dalam mengenali lima kelas motif batik.

Melalui rangkaian proses tersebut, praktikum ini bertujuan untuk memahami penerapan teknik pengolahan citra, evaluasi kualitas citra, ekstraksi fitur, dan klasifikasi dalam *computer vision*, serta mengetahui perbedaan hasil yang diperoleh dari metode yang digunakan.

1.2 Tujuan

1. Menerapkan tahapan pengolahan citra, mulai dari konversi *grayscale*, peningkatan kualitas citra, hingga *median filtering*.
2. Membandingkan hasil metode *Histogram Equalization*, *Contrast Stretching*, dan CLAHE berdasarkan nilai MSE dan PSNR.

3. Mengekstraksi fitur motif batik menggunakan metode LBP dan SIFT dengan pendekatan BoVW.
4. Menerapkan klasifikasi SVM untuk mengenali lima kelas motif batik berdasarkan fitur yang diekstraksi.
5. Membandingkan hasil klasifikasi berdasarkan akurasi yang diperoleh dari setiap kombinasi metode peningkatan kualitas citra dan ekstraksi fitur.

BAB II
METODOLOGI

2.1 Dataset

Dataset yang digunakan dalam praktikum ini adalah *Indonesian Batik Motifs* yang diperoleh dari Kaggle. Dataset asli terdiri dari 983 citra yang terbagi ke dalam 20 kelas motif batik Indonesia.

Pada praktikum ini, penggunaan dataset dibatasi menjadi lima kelas, yaitu Batik Ceplok, Batik Kawung, Batik Megamendung, Batik Parang, dan Batik Tambal. Berdasarkan hasil pembacaan data oleh program, terdapat 239 citra dari kelima kelas tersebut yang digunakan dalam proses pengolahan citra dan klasifikasi.

Seluruh citra yang digunakan diubah ukurannya menjadi 256 × 256 piksel sebelum memasuki tahap pengolahan berikutnya. Kelima kelas tersebut kemudian digunakan untuk membandingkan hasil peningkatan kualitas citra, ekstraksi fitur, dan klasifikasi menggunakan metode yang telah ditentukan.

2.2 Preprocessing

Tahap *preprocessing* dilakukan untuk menyeragamkan data citra sebelum memasuki tahap peningkatan kualitas citra dan ekstraksi fitur. Pada tahap ini, program melakukan dua proses utama, yaitu mengubah ukuran citra dan mengonversi citra menjadi *grayscale*.

Pertama, setiap citra diubah ukurannya menjadi 256 × 256 piksel agar seluruh data memiliki dimensi yang seragam. Selanjutnya, citra dikonversi dari format berwarna menjadi *grayscale*, sehingga informasi yang digunakan pada tahap pengolahan berikutnya berupa intensitas keabuan, bukan kombinasi tiga kanal warna RGB.

Hasil *preprocessing* tersebut kemudian digunakan sebagai masukan untuk tiga metode peningkatan kualitas citra, yaitu *Histogram Equalization*, *Contrast Stretching*, dan CLAHE. Setelah proses peningkatan kualitas, citra diproses menggunakan *median filtering* dengan ukuran kernel 3 × 3 sebelum dilakukan evaluasi MSE dan PSNR serta ekstraksi fitur.

2.3 Enhancement dan Filtering

Tahap enhancement dilakukan untuk meningkatkan kontras citra agar pola dan tekstur motif batik dapat terlihat dengan lebih jelas. Pada praktikum ini, tiga metode enhancement diaplikasikan secara terpisah pada citra grayscale hasil preprocessing. Dengan demikian, setiap

citra menghasilkan tiga variasi citra yang dapat dibandingkan berdasarkan hasil peningkatan kontrasnya.

Metode pertama yang digunakan adalah Histogram Equalization (HE). Metode ini meningkatkan kontras dengan mendistribusikan intensitas keabuan berdasarkan fungsi distribusi kumulatif (Cumulative Distribution Function atau CDF) dari histogram citra. Transformasi intensitas untuk tingkat keabuan r_k dirumuskan pada Persamaan 2.1.

$$s_k = round\left((L - 1)\sum_{j=0}^{k} p\left(r_j\right)\right) \tag{2.1}$$

Pada persamaan tersebut, s_k merupakan nilai keabuan hasil transformasi, L adalah jumlah tingkat keabuan sebanyak 256, dan $p(r_j)$ menyatakan probabilitas kemunculan tingkat keabuan r_j, yang dihitung menggunakan persamaan berikut.

$$p\left(r_j\right) = \frac{n_j}{n}$$

Dengan n_j merupakan jumlah piksel pada tingkat keabuan r_j, sedangkan n adalah jumlah seluruh piksel citra. HE termasuk metode peningkatan kontras global karena menggunakan satu fungsi transformasi untuk seluruh bagian citra. Implementasi metode ini dilakukan menggunakan fungsi cv2.equalizeHist. Ijaz (2023) melaporkan bahwa HE mampu meningkatkan kualitas citra, meskipun peningkatannya tergolong moderat dibandingkan dengan metode lain yang dievaluasi.

Metode kedua adalah Contrast Stretching (CS), yaitu teknik peningkatan kontras dengan memperluas rentang intensitas piksel ke rentang 0–255 melalui transformasi linier. Dalam praktikum ini, persentil ke-2 (p_2) dan persentil ke-98 (p_{98}) digunakan sebagai batas bawah dan batas atas intensitas. Pemilihan kedua persentil tersebut bertujuan mengurangi pengaruh piksel ekstrem terhadap proses peregangan kontras. Nilai piksel yang berada di luar rentang tersebut dibatasi menjadi 0 atau 255, sebagaimana ditunjukkan pada Persamaan 2.2.

$$s = min\left(255,\ max\left(0,\ \frac{r - p_2}{p_{98} - p_2} \times 255\right)\right) \tag{2.2}$$

Variabel r menunjukkan intensitas piksel sebelum transformasi, sedangkan s merupakan intensitas setelah transformasi. Berbeda dengan HE yang mendistribusikan ulang intensitas berdasarkan histogram, CS mempertahankan hubungan linier antarnilai intensitas dalam rentang

yang digunakan, tetapi memperluas rentang penyebarannya. Penggunaan Contrast Stretching bersama HE juga ditemukan dalam penelitian Sidik et al. (2019), khususnya pada tahap prapengolahan citra malam hari yang diawali dengan konversi ke grayscale.

Metode ketiga adalah Contrast Limited Adaptive Histogram Equalization (CLAHE). Metode ini merupakan pengembangan dari HE yang melakukan peningkatan kontras secara lokal. Citra terlebih dahulu dibagi menjadi sejumlah blok kecil atau tile, kemudian histogram equalization diterapkan pada setiap blok. Untuk mencegah peningkatan kontras yang berlebihan, frekuensi histogram yang melampaui batas clip limit dipotong dan kelebihannya didistribusikan kembali ke bin lainnya. Selanjutnya, interpolasi digunakan untuk menghaluskan transisi antartile agar tidak menimbulkan batas yang mencolok pada citra.

CLAHE diimplementasikan menggunakan fungsi cv2.createCLAHE dengan nilai clip limit sebesar 2,0 dan ukuran tile 8 × 8. Pada citra berukuran 256 × 256 piksel, konfigurasi tersebut membagi citra menjadi delapan bagian pada setiap dimensi, dengan ukuran setiap tile sebesar 32 × 32 piksel. Penelitian Supriyanti et al. (2017) menunjukkan bahwa CLAHE menghasilkan kinerja terbaik dibandingkan dengan beberapa varian HE lainnya pada citra ultrasonografi beresolusi rendah.

Setelah enhancement selesai, setiap citra hasil diproses menggunakan median filter dengan ukuran kernel 3 × 3. Filtering ini bertujuan mengurangi noise yang berpotensi ikut diperkuat selama peningkatan kontras. Median filter bekerja dengan mengganti nilai suatu piksel menggunakan nilai median dari piksel-piksel pada jendela di sekitarnya, sebagaimana dirumuskan pada Persamaan 2.3.

$$y(i,j) = median_{(m,n)\in W}\, x(i+m, j+n) \qquad (2.3)$$

Pada persamaan tersebut, x merupakan citra masukan, y adalah citra keluaran, dan W merupakan jendela berukuran 3 × 3 yang terdiri atas sembilan piksel. Penggunaan nilai median membuat filter ini relatif tahan terhadap piksel bernilai ekstrem dibandingkan dengan filter yang menggunakan nilai rata-rata. Sidik et al. (2019) juga menerapkan median filter untuk mengurangi noise dalam rangkaian prapengolahan yang melibatkan HE dan CS. Dalam praktikum ini, proses filtering dilakukan menggunakan fungsi cv2.medianBlur. Citra yang telah melalui tahap enhancement dan filtering selanjutnya digunakan untuk menghitung MSE dan PSNR serta menjadi masukan dalam proses ekstraksi fitur.

2.4 Evaluasi MSE dan PSNR

Evaluasi hasil preprocessing dilakukan menggunakan dua metrik, yaitu Mean Squared Error (MSE) dan Peak Signal-to-Noise Ratio (PSNR). MSE digunakan untuk mengukur rata-rata kuadrat perbedaan intensitas piksel antara citra referensi I dan citra hasil K yang memiliki dimensi $M \times N$. Perhitungan MSE ditunjukkan pada Persamaan 2.4.

$$MSE = \frac{1}{M \times N} \sum_{i=1}^{M} \sum_{j=1}^{N} [I(i,j) - K(i,j)]^2 \tag{2.4}$$

Sementara itu, PSNR digunakan untuk menyatakan perbandingan antara nilai intensitas maksimum citra dengan tingkat kesalahan yang diukur melalui MSE dalam satuan desibel (dB). Untuk citra 8-bit dengan intensitas maksimum 255, PSNR dihitung menggunakan Persamaan 2.5.

$$PSNR = 10 \log_{10}\left(\frac{255^2}{MSE}\right) \tag{2.5}$$

Secara umum, nilai MSE yang lebih rendah dan PSNR yang lebih tinggi menunjukkan bahwa perbedaan antara citra hasil dan citra referensi semakin kecil. Pada praktikum ini, citra grayscale hasil preprocessing digunakan sebagai citra referensi, sedangkan citra setelah enhancement dan median filtering menjadi citra yang dievaluasi. Perhitungan kedua metrik dilakukan pada setiap citra untuk masing-masing metode enhancement menggunakan fungsi mse dan psnr yang telah didefinisikan dalam program.

Hasil pengukuran kemudian dirangkum dengan menghitung nilai rata-rata MSE dan PSNR untuk seluruh citra pada setiap metode, serta berdasarkan masing-masing kelas. Seluruh hasil tersebut disimpan dalam berkas CSV untuk memudahkan analisis dan perbandingan antarmetode.

Meskipun demikian, interpretasi kedua metrik perlu mempertimbangkan karakteristik proses enhancement. Peningkatan kontras memang dirancang untuk mengubah distribusi intensitas piksel sehingga citra hasil tidak sepenuhnya identik dengan citra grayscale awal. Oleh sebab itu, MSE dan PSNR pada praktikum ini lebih tepat digunakan untuk mengukur besarnya perubahan intensitas terhadap citra referensi, bukan sebagai satu-satunya indikator kualitas visual. Hal ini sejalan dengan temuan Sidik et al. (2019) bahwa nilai PSNR yang lebih tinggi tidak selalu menunjukkan kualitas visual yang lebih baik. Dengan demikian, evaluasi hasil

enhancement sebaiknya turut mempertimbangkan tampilan visual citra dan kejelasan pola motif batik yang dihasilkan.

2.5 Ekstraksi Fitur LBP Multi-Skala

Local Binary Pattern (LBP) merangkum tekstur citra menjadi 80 angka, yaitu gabungan histogram pola lokal dari empat skala.

$$LBP_{P,R} = \sum s(G_p - G_c)\, 2^P \qquad (2.6)$$

Cara kerjanya:

1. Untuk tiap piksel, ambil P piksel tetangga pada lingkaran berjari-jari R.
2. Bandingkan tiap tetangga dengan piksel pusat: 1 jika lebih besar atau sama, 0 jika lebih kecil. Hasilnya kode biner P bit.
3. Kelompokkan kode menjadi pola *uniform* (paling banyak dua pergantian 0–1 dalam satu putaran) dan satu kelompok untuk pola lainnya. Jumlah kelompoknya P + 2.
4. Hitung histogram kelompok itu atas seluruh citra, lalu normalisasi sehingga jumlahnya 1.
5. Ulangi untuk tiap skala dan gabungkan semua histogram.

2.6 Ekstraksi Fitur SIFT dengan BoVW

Scale-Invariant Feature Transform (SIFT) merupakan metode ekstraksi fitur yang digunakan untuk merepresentasikan karakteristik lokal citra berdasarkan arah dan besar gradien intensitas. Pada penelitian ini, SIFT dikombinasikan dengan pendekatan Bag of Visual Words (BoVW) untuk mengubah informasi visual pada citra motif batik menjadi representasi numerik yang dapat digunakan dalam proses klasifikasi. Pendekatan ini digunakan untuk menangkap karakteristik bentuk dan pola lokal pada lima kelas motif batik, yaitu Ceplok, Kawung, Megamendung, Parang, dan Tambal.

Tahap pertama dalam ekstraksi fitur SIFT-BoVW adalah menentukan titik-titik pengambilan fitur pada citra. Berbeda dengan SIFT standar yang mendeteksi titik penting secara otomatis, implementasi pada praktikum ini menggunakan pendekatan dense SIFT, yaitu menempatkan titik-titik secara teratur pada grid dengan jarak 8 piksel. Ekstraksi dilakukan menggunakan dua ukuran titik, yaitu 8 dan 16 piksel, untuk memperoleh informasi pola lokal pada ukuran yang berbeda. Dengan ukuran citra 256 × 256 piksel, proses ini menghasilkan 1.684 titik ekstraksi untuk setiap citra.

Setelah titik ekstraksi ditentukan, program menghitung deskriptor SIFT pada setiap titik. Area di sekitar titik dibagi menjadi 4 × 4 sel, kemudian setiap sel direpresentasikan menggunakan histogram delapan arah gradien. Dengan demikian, setiap deskriptor memiliki 128 nilai yang menggambarkan karakteristik gradien lokal. Informasi tersebut digunakan untuk merepresentasikan struktur visual, seperti garis, sudut, lengkungan, dan perubahan intensitas pada motif batik.

Selanjutnya, deskriptor diproses menggunakan RootSIFT, yaitu pendekatan normalisasi deskriptor yang dilanjutkan dengan transformasi akar kuadrat. Proses ini bertujuan menghasilkan representasi yang lebih sesuai untuk membandingkan distribusi deskriptor. Setelah itu, deskriptor digunakan dalam pembentukan kamus visual atau visual vocabulary menggunakan algoritma K-Means.

Pembentukan kamus visual dilakukan dengan mengelompokkan deskriptor yang memiliki karakteristik serupa ke dalam sejumlah kelompok. Setiap pusat kelompok disebut sebagai visual word, yang mewakili pola visual lokal tertentu. Pada praktikum ini, jumlah visual word ditetapkan sebanyak 256. Untuk membatasi jumlah data yang diproses, program mengambil 300 deskriptor secara acak dari setiap citra latih. Berdasarkan 191 citra latih, diperoleh total 57.300 deskriptor yang digunakan untuk membentuk kamus visual. Data uji tidak digunakan dalam proses pembentukan kamus agar tidak terjadi kebocoran informasi dari data pengujian.

Setelah kamus visual terbentuk, setiap deskriptor pada citra dipetakan ke visual word terdekat berdasarkan jaraknya terhadap pusat kelompok. Jumlah kemunculan masing-masing visual word kemudian dihitung dan disusun menjadi histogram dengan 256 elemen. Histogram tersebut dinormalisasi dan ditransformasikan menggunakan akar kuadrat untuk menghasilkan representasi akhir setiap citra. Dengan demikian, setiap citra motif batik direpresentasikan oleh 256 fitur numerik yang menggambarkan distribusi pola visual lokal.

Secara matematis, representasi BoVW dapat dinyatakan melalui histogram berikut:

$$H_i(k) = \sum_{j=i}^{N_i} 1(w_j = k) \tag{2.7}$$

Keterangan simbol:

Hi(k): jumlah kemunculan visual word ke-k pada citra ke-i.

Ni: jumlah seluruh visual word pada citra ke-i.

wj: visual word pada posisi ke-j.

1(wj=k): bernilai 1 jika wj=k, dan 0 jika tidak.

Histogram yang dihasilkan selanjutnya digunakan sebagai masukan pada tahap klasifikasi menggunakan Support Vector Machine (SVM). Melalui pendekatan SIFT-BoVW, informasi visual lokal yang jumlahnya banyak diringkas menjadi vektor berdimensi tetap sehingga setiap citra dapat dibandingkan dan diklasifikasikan secara komputasional.

2.7 Klasifikasi SVM

Support Vector Machine (SVM) merupakan metode pembelajaran mesin yang digunakan untuk melakukan klasifikasi berdasarkan karakteristik atau fitur yang diperoleh dari data. Dalam praktikum ini, SVM digunakan untuk mengenali lima kelas motif batik, yaitu Ceplok, Kawung, Megamendung, Parang, dan Tambal. Proses klasifikasi dilakukan menggunakan fitur hasil ekstraksi Local Binary Pattern (LBP) multi-skala dan SIFT dengan pendekatan Bag of Visual Words (BoVW). Penggunaan SVM memungkinkan perbandingan kemampuan kedua metode ekstraksi fitur dalam membedakan karakteristik visual setiap motif batik.

Prinsip kerja SVM adalah mencari batas keputusan atau hyperplane yang dapat memisahkan data dari kelas-kelas yang berbeda. Pada klasifikasi dengan dua kelas, SVM berusaha memperoleh hyperplane dengan margin terbesar terhadap data terdekat dari masing-masing kelas. Untuk permasalahan dengan lebih dari dua kelas seperti pada praktikum ini, model SVM digunakan untuk menentukan kelas yang paling sesuai berdasarkan fitur masukan. Kemampuan pemisahan data dipengaruhi oleh karakteristik fitur dan parameter yang digunakan dalam model.

Secara umum, optimasi SVM dengan pendekatan soft margin dapat dirumuskan sebagai berikut:

$$min_{w,b,\xi} \frac{1}{2}||w||^2 + C \sum_{i=1}^{n} \xi_i \quad (2.8)$$

dengan kendala:

$$y_i(w^t \phi(x_i) + b) \geq 1 - \xi_i \quad (2.9)$$

$$\xi_i \geq 0 \tag{2.10}$$

Pada implementasi praktikum ini, proses klasifikasi diawali dengan membagi dataset yang terdiri dari 239 citra menjadi data latih dan data uji dengan perbandingan 80:20. Pembagian tersebut menghasilkan 191 citra untuk data latih dan 48 citra untuk data uji. Proporsi kelas dipertahankan pada kedua bagian agar distribusi lima kelas motif batik tetap terwakili. Seluruh fitur yang digunakan kemudian distandarkan sebelum proses pelatihan SVM sehingga perbedaan skala nilai fitur tidak mendominasi proses klasifikasi.

Tahap berikutnya adalah menentukan parameter model menggunakan metode 5-fold cross-validation pada data latih. Dalam metode ini, data latih dibagi menjadi lima bagian. Secara bergantian, empat bagian digunakan untuk melatih model, sedangkan satu bagian digunakan untuk validasi. Proses tersebut diulang hingga setiap bagian memperoleh giliran sebagai data validasi. Hasil validasi digunakan untuk membandingkan konfigurasi parameter SVM dan memilih konfigurasi yang memberikan kinerja terbaik berdasarkan prosedur evaluasi yang diterapkan.

Parameter yang dievaluasi meliputi jenis kernel, nilai (C), dan gamma. Kernel digunakan untuk menentukan bentuk fungsi pemisah yang diterapkan pada data. Pada eksperimen ini, kernel Linear dan Radial Basis Function (RBF) digunakan sebagai alternatif. Kernel Linear membentuk batas keputusan linear pada ruang fitur, sedangkan kernel RBF memungkinkan pembentukan batas keputusan nonlinier. Parameter (C) mengatur penalti terhadap kesalahan klasifikasi, sementara gamma pada kernel RBF mengatur jangkauan pengaruh setiap data latih terhadap fungsi keputusan.

Setelah konfigurasi terbaik diperoleh melalui cross-validation, model dilatih menggunakan data latih dan dievaluasi pada 48 citra data uji yang tidak digunakan dalam pemilihan parameter. Evaluasi dilakukan untuk mengukur kemampuan model dalam mengenali motif batik yang belum digunakan selama pelatihan. Metrik yang digunakan meliputi akurasi dan Macro F1-score. Akurasi menunjukkan proporsi prediksi yang benar terhadap seluruh data uji, sedangkan Macro F1-score menghitung rata-rata F1-score dari setiap kelas dengan bobot yang sama.

Akurasi dihitung menggunakan persamaan berikut:

$$Accuracy = \frac{TP + TN}{TP+TN+FP+FN} \quad (2.11)$$

Untuk klasifikasi multikelas, akurasi diperoleh dari jumlah seluruh prediksi yang benar dibagi dengan jumlah keseluruhan data uji. Sementara itu, F1-score dihitung berdasarkan precision dan recall:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision\ Recall} \quad (2.12)$$

Nilai Macro F1-score diperoleh dengan menghitung F1-score masing-masing kelas, kemudian mengambil rata-rata tanpa memberikan bobot berdasarkan jumlah data pada setiap kelas.

Eksperimen dilakukan terhadap enam kombinasi metode enhancement dan ekstraksi fitur, yaitu HE dengan LBP, HE dengan SIFT-BoVW, Contrast Stretching dengan LBP, Contrast Stretching dengan SIFT-BoVW, CLAHE dengan LBP, serta CLAHE dengan SIFT-BoVW. Perbandingan ini bertujuan mengetahui pengaruh metode peningkatan kualitas citra dan ekstraksi fitur terhadap kinerja klasifikasi SVM. Hasil cross-validation dan pengujian pada data uji selanjutnya digunakan untuk mengidentifikasi kombinasi metode yang memberikan kinerja terbaik dalam pengenalan motif batik.

Melalui tahapan tersebut, klasifikasi SVM menjadi tahap akhir dalam rangkaian pengolahan citra pada praktikum ini. Hasil klasifikasi digunakan untuk membandingkan kemampuan LBP multi-skala dan SIFT-BoVW dalam merepresentasikan karakteristik motif batik, sekaligus mengevaluasi pengaruh Histogram Equalization, Contrast Stretching, dan CLAHE terhadap hasil pengenalan lima kelas motif batik Indonesia.

BAB III
HASIL DAN PEMBAHASAN

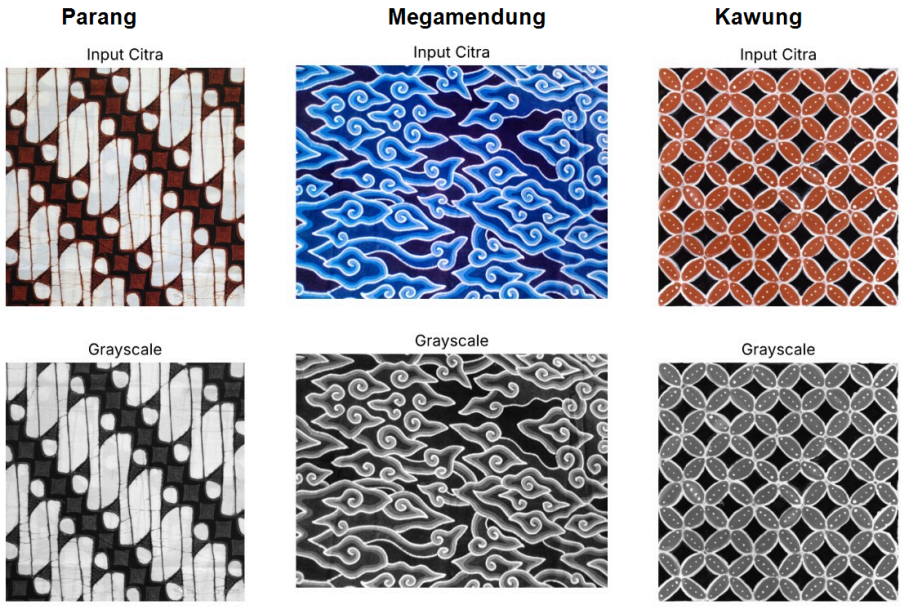
3.1 Hasil Preprocessing

Tahap preprocessing dilakukan untuk menyiapkan citra batik sebelum proses peningkatan kontras dan ekstraksi fitur. Berdasarkan visualisasi hasil, citra masukan berwarna dikonversi menjadi citra grayscale. Konversi ini menghasilkan representasi satu kanal intensitas sehingga pengolahan berikutnya berfokus pada perbedaan tingkat keabuan, bentuk, dan tekstur motif.

Hasil konversi menunjukkan bahwa struktur utama motif masih dapat diamati meskipun informasi warna tidak lagi dipertahankan. Pada citra batik parang, pola memanjang dan batas antara bagian terang dengan latar gelap tetap terlihat. Pada citra megamendung, bentuk menyerupai awan beserta garis lengkungnya masih dapat dikenali. Sementara itu, citra kawung tetap memperlihatkan susunan pola oval yang berulang secara teratur. Dengan demikian, citra grayscale masih memuat informasi visual yang relevan untuk analisis tekstur dan bentuk.

Histogram grayscale memperlihatkan distribusi intensitas yang berbeda pada setiap contoh citra. Citra parang memiliki konsentrasi piksel pada intensitas rendah dan tinggi, sesuai dengan adanya latar gelap dan bidang motif yang terang. Citra megamendung memperlihatkan beberapa kelompok intensitas yang berkaitan dengan variasi tingkat keabuan pada motif dan latarnya. Pada citra kawung, konsentrasi intensitas terlihat pada bagian gelap, keabuan menengah, dan bagian terang pembentuk batas motif.

Pada visualisasi ekstraksi fitur, citra masukan ditampilkan dengan ukuran 128 × 128 piksel. Penyeragaman ukuran memberikan dimensi spasial yang sama bagi citra sebelum fitur dihitung. Namun, pengecilan ukuran juga berpotensi mengurangi keterlihatan detail motif yang halus. Oleh karena itu, hasil ekstraksi fitur dipengaruhi oleh informasi tekstur yang masih dipertahankan setelah penyesuaian ukuran.



Gambar 3.1 Citra asli dan grayscale tiga motif.

3.2 Hasil Enhancement dan Filtering

Peningkatan kontras dilakukan menggunakan tiga metode, yaitu Histogram Equalization (HE), Contrast Stretching (CS), dan Contrast Limited Adaptive Histogram Equalization (CLAHE). Hasil setiap metode kemudian diproses menggunakan filter median. Perbandingan dilakukan dengan mengamati perubahan tampilan motif serta distribusi intensitas pada histogram.

Pada contoh citra yang ditampilkan, HE menghasilkan perubahan tingkat keabuan yang relatif mencolok. Bagian motif yang sebelumnya memiliki intensitas berdekatan tampak mengalami pemisahan tingkat keabuan yang lebih kuat. Pada citra parang, detail di dalam bidang motif terang menjadi lebih terlihat, tetapi penampilan citra juga berubah cukup besar dibandingkan citra grayscale. Histogram hasil HE + Median memperlihatkan distribusi intensitas yang tersebar dengan sejumlah puncak yang tajam. Hasil tersebut menunjukkan bahwa pemerataan histogram tidak selalu menghasilkan histogram akhir yang datar.

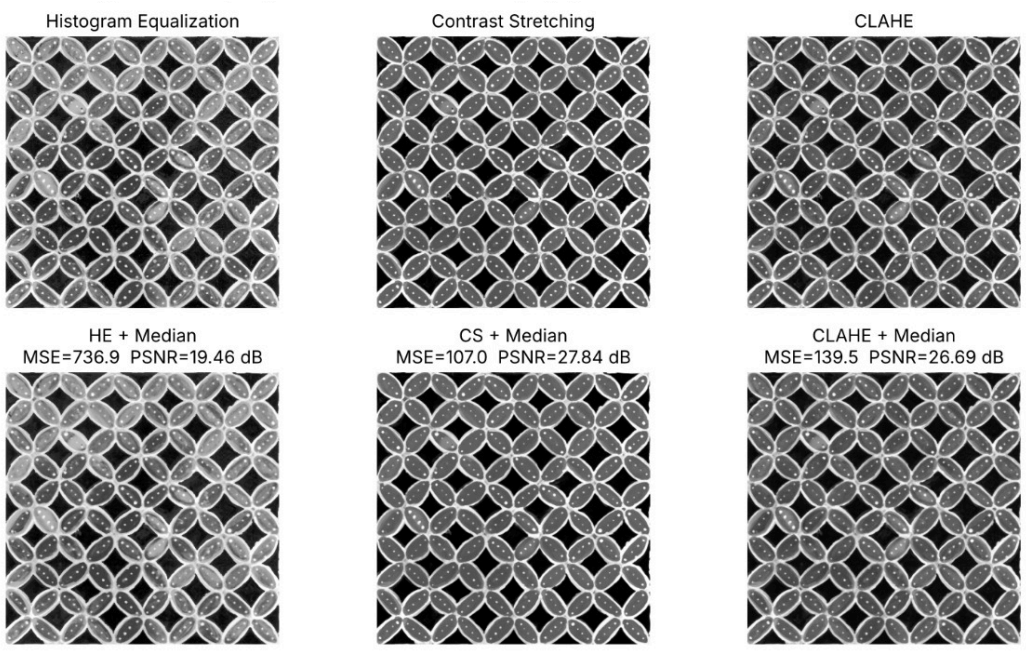
CS mempertahankan tampilan struktur motif yang relatif dekat dengan citra grayscale pada contoh yang diamati. Perbedaan antara latar gelap dan garis motif terang tetap terlihat jelas, terutama pada citra parang dan kawung. Distribusi histogramnya masih memperlihatkan

kelompok intensitas dominan yang menyerupai karakter citra awal, meskipun posisi dan rentang intensitasnya mengalami perubahan.

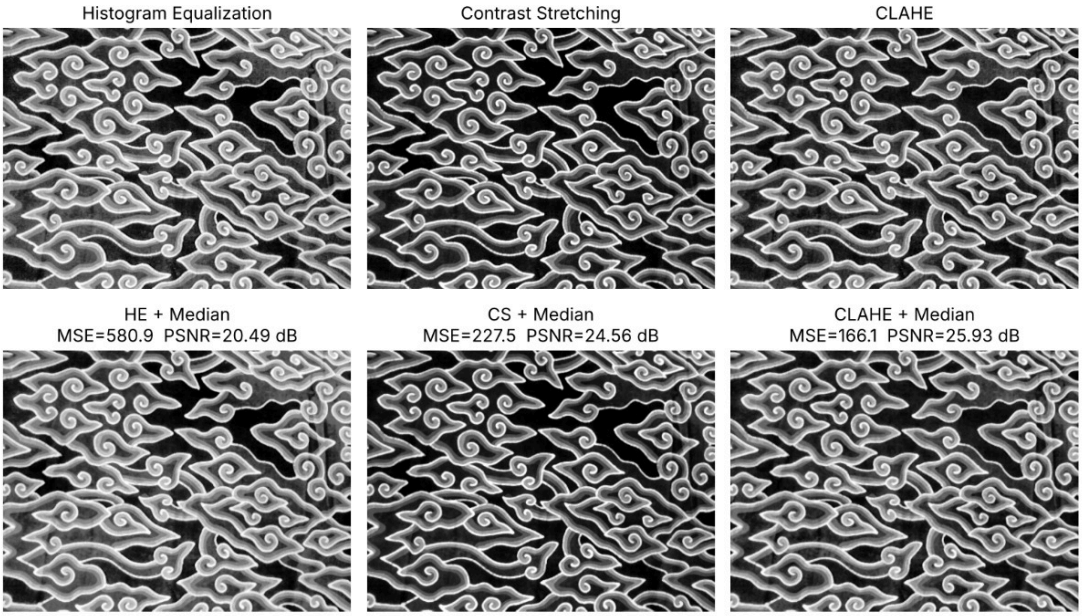
CLAHE menghasilkan penyesuaian kontras lokal. Pada citra megamendung, garis lengkung dan batas antarlapisan motif terlihat jelas setelah pemrosesan. Pada citra kawung, batas pola oval dan titik-titik kecil di dalamnya masih dapat diamati. Secara visual, hasil CLAHE memperlihatkan perubahan kontras pada detail motif tanpa perubahan tampilan global sebesar HE pada contoh-contoh tersebut.

Filter median digunakan setelah enhancement untuk menghaluskan variasi intensitas lokal. Berdasarkan pasangan citra sebelum dan sesudah filtering, struktur utama motif tetap dipertahankan, sedangkan sebagian detail kecil tampak lebih halus. Akan tetapi, karena tidak tersedia pengukuran noise sebelum dan sesudah filtering, besarnya pengurangan noise belum dapat dinyatakan secara kuantitatif.

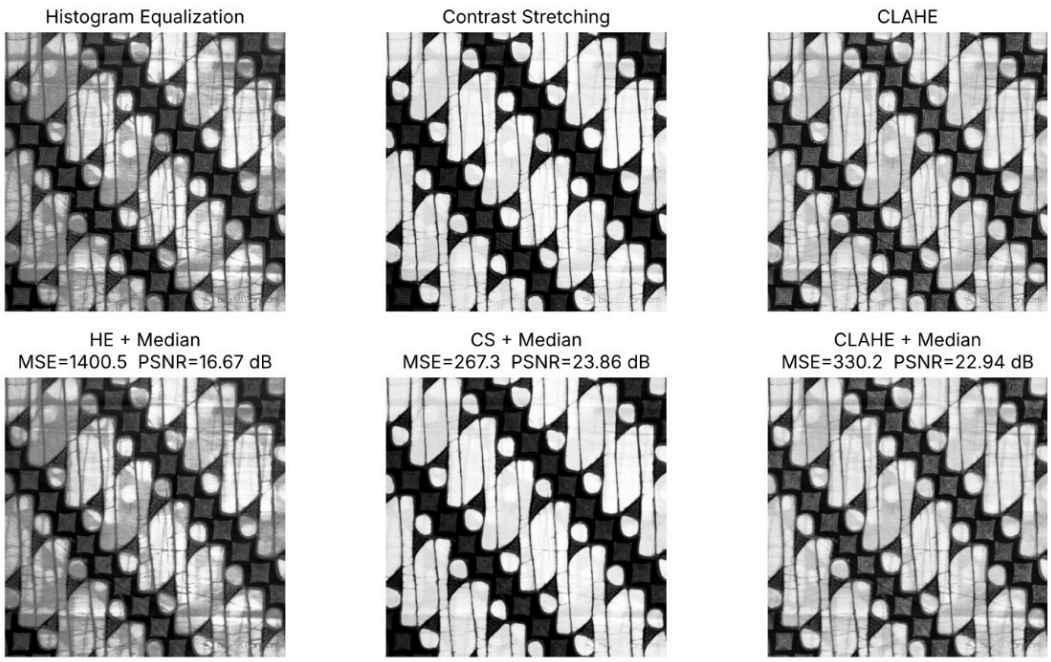
Hasil pengamatan menunjukkan bahwa pengaruh enhancement bergantung pada karakteristik citra. Metode yang memberikan hasil sesuai pada satu motif belum tentu menghasilkan perubahan yang sama pada motif lainnya. Oleh sebab itu, penilaian visual perlu dilengkapi dengan pengukuran MSE dan PSNR serta evaluasi klasifikasi.



Gambar 3.2 Tahapan pemrosesan batik kawung



Gambar 3.3 Tahapan pemrosesan batik megamendung



Gambar 3.4 Tahapan pemrosesan batik parang

3.3 Hasil MSE dan PSNR

MSE dan PSNR dihitung untuk setiap citra dengan membandingkan citra grayscale hasil preprocessing (acuan) dengan citra hasil enhancement dan median filtering. Nilai per citra kemudian dirata-ratakan untuk 239 citra. Rata-rata PSNR diperoleh dari PSNR setiap citra, bukan dari PSNR rata-rata MSE. Tabel 3.1 menunjukkan hasil untuk setiap metode.

Tabel 3.1 Rata-rata MSE dan PSNR setiap metode enhancement

Metode	Rata-rata MSE	Rata-rata PSNR (dB)	Simpangan baku PSNR	PSNR terendah	PSNR tertinggi
HE	2332.93	15.57	3.12	08.02	24.24
Contrast Stretching	1136.76	19.16	3.50	5.42	30.62
CLAHE	965.67	19.20	2.98	9.24	32.90

HE menghasilkan perubahan terbesar terhadap citra acuan. Rata-rata MSE HE sebesar 2332,93, sekitar dua kali MSE kedua metode lainnya. PSNR-nya sekitar 3,6 dB lebih rendah. Hal ini terjadi karena HE memetakan ulang seluruh tingkat keabuan berdasarkan distribusi kumulatif citra secara global, sehingga area gelap dan terang yang luas ikut bergeser.

Contrast Stretching dan CLAHE memiliki rata-rata PSNR yang hampir sama, yaitu 19,16 dB dan 19,20 dB. Namun, rata-rata MSE Contrast Stretching lebih tinggi, yaitu 1136,76 dibanding 965,67. Perbedaan ini disebabkan oleh sebagian citra yang mengalami perubahan sangat besar pada Contrast Stretching, dengan PSNR terendah 5,42 dB. Besarnya perubahan pada Contrast Stretching bergantung pada rentang intensitas citra. Jika jarak antara persentil ke-2 dan ke-98 sempit, penguatan kontrasnya besar dan citra berubah drastis. Sebaliknya, jika rentangnya sudah lebar, citra hampir tidak berubah. Hal ini juga terlihat dari jumlah citra dengan PSNR tertinggi. Contrast Stretching unggul pada 122 citra, CLAHE pada 100 citra, dan HE pada 17 citra.

CLAHE merupakan metode yang paling konsisten, dengan simpangan baku PSNR terkecil yaitu 2,98. Pembatasan kontras melalui clip limit pada setiap blok mencegah perubahan intensitas yang berlebihan, sehingga hasilnya lebih stabil antarcitra.

Tabel 3.2 Rata-rata MSE dan PSNR per kelas

Kelas	MSE HE	MSE CS	MSE CLAHE	PSNR HE (dB)	PSNR CS (dB)	PSNR CLAHE (dB)
Ceplok	2058,59	1148,64	1129,36	15,85	18,99	18,69
Kawung	2502,46	1922,12	958,53	14,91	17,26	19,62
Megamendung	2135,25	738,08	698,45	16,34	20,93	20,52
Parang	2507,45	1085,02	1045,24	15,16	18,95	18,61
Tambal	2451,08	837,05	981,26	15,59	19,62	18,71

Berdasarkan Tabel 3.2, motif megamendung paling sedikit berubah, dengan PSNR tertinggi pada ketiga metode. Motif kawung paling banyak berubah, dengan PSNR terendah pada HE (14,91 dB) dan Contrast Stretching (17,26 dB). Namun, pada CLAHE, kawung justru memiliki PSNR tertinggi kedua, yaitu 19,62 dB. Selisih PSNR kawung antara Contrast Stretching dan CLAHE mencapai 2,36 dB, yang terbesar di antara kelima kelas.

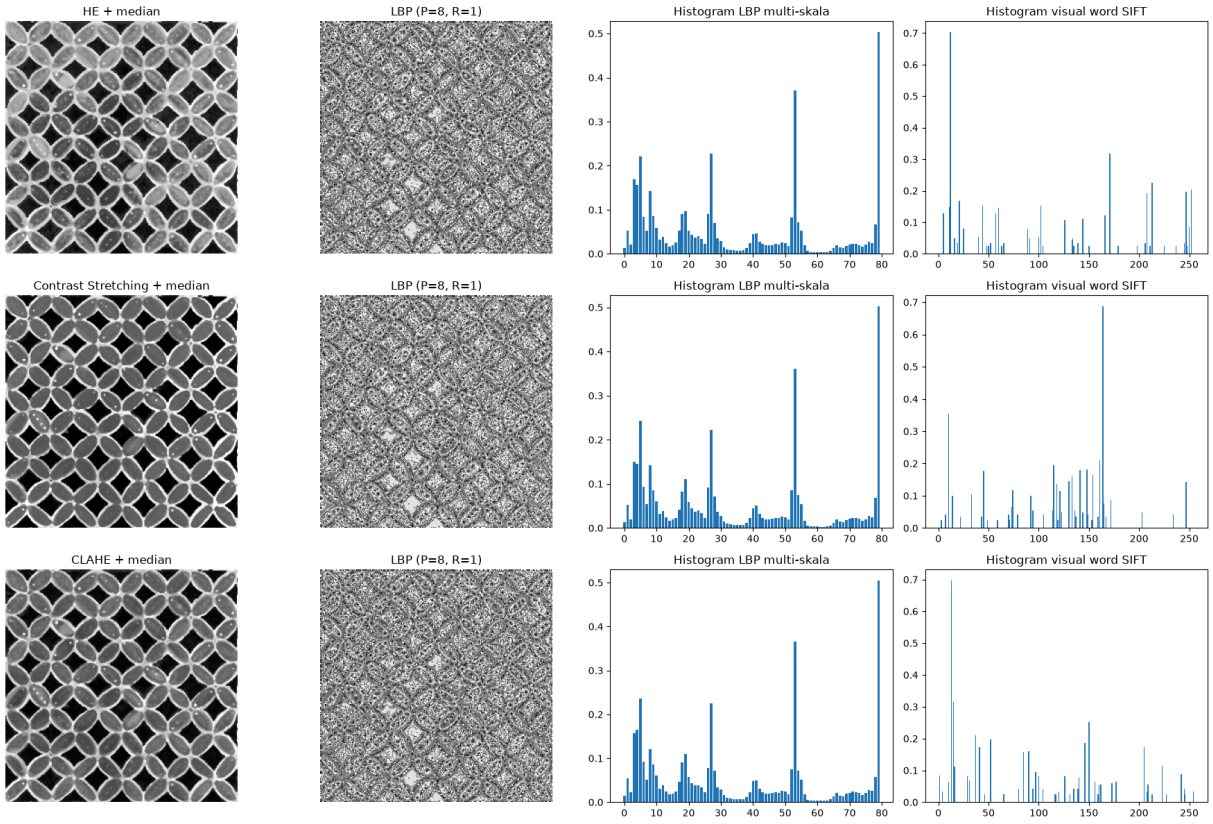
Jika dilihat per kelas, Contrast Stretching menghasilkan PSNR lebih tinggi daripada CLAHE pada empat kelas, yaitu ceplok, megamendung, parang, dan tambal. CLAHE hanya unggul pada kelas kawung. Namun, keunggulan CLAHE pada kawung cukup besar sehingga rata-rata PSNR keseluruhan CLAHE sedikit lebih tinggi. Hal ini menunjukkan bahwa perbedaan kedua metode secara keseluruhan sangat kecil dan bergantung pada karakteristik setiap kelas.

Perlu diperhatikan bahwa nilai MSE dan PSNR pada praktikum ini menunjukkan besarnya perubahan terhadap citra grayscale, bukan kualitas visual. MSE yang tinggi pada HE tidak berarti hasilnya buruk untuk ekstraksi fitur. Pengaruh setiap metode terhadap kemampuan membedakan motif batik dibahas pada Subbab 3.6.

3.4 Hasil Ekstraksi Fitur LBP

Local Binary Pattern (LBP) merupakan metode ekstraksi fitur yang digunakan untuk mengenali tekstur pada citra berdasarkan perbandingan intensitas piksel pusat dengan piksel tetangganya. Pada percobaan ini, LBP diterapkan menggunakan empat skala untuk menangkap pola tekstur pada jarak yang berbeda. Setiap skala menggunakan kombinasi jumlah piksel tetangga ((P)) dan radius ((R)) yang berbeda, yaitu (P=8, R=1), (P=16, R=2), (P=24, R=3), dan (P=24, R=5). Hasil ekstraksi dari setiap skala kemudian digabungkan menjadi histogram dengan

total 80 fitur. Proses ini bertujuan untuk mendapatkan representasi tekstur motif batik yang lebih beragam dibandingkan penggunaan satu skala saja.



Gambar 3.5 Hasil ekstraksi fitur LBP

Peta LBP dapat menunjukkan garis tepi pada motif yang terdeteksi. Pada kolom kedua, bentuk elips pada motif kawung terlihat seperti garis, sedangkan bagian yang memiliki warna relatif rata terlihat sebagai bintik-bintik acak. Pada histogram, batang tertinggi berada di posisi 27, 53, dan 79, yang menunjukkan kelompok pola non-uniform. Pada radius 5, hampir setengah piksel termasuk dalam kelompok ini karena penggunaan 24 piksel tetangga dengan jarak yang lebih jauh menghasilkan pola yang lebih beragam. Selain itu, histogram LBP pada ketiga metode enhancement menunjukkan hasil yang hampir sama. Hal ini karena LBP bekerja berdasarkan perbandingan intensitas piksel pusat dengan piksel tetangganya. Metode Histogram Equalization (HE) dan Contrast Stretching mengubah nilai keabuan citra tanpa banyak mengubah urutan intensitas piksel, sehingga kode LBP yang dihasilkan hampir tidak mengalami perubahan.

Penggunaan satu skala LBP belum cukup untuk menghasilkan klasifikasi yang baik. LBP dengan parameter P=8 dan R=1 hanya mengambil informasi dari piksel tetangga yang berjarak

satu piksel. Pada pengujian terhadap 20 kelas, akurasi yang diperoleh berada pada rentang 0,20 hingga 0,22, kemudian meningkat menjadi 0,26 setelah menggunakan empat skala. Hasil ini menunjukkan bahwa penggunaan beberapa skala dapat membantu menangkap informasi tekstur motif dari jarak yang berbeda. Namun, LBP memiliki keterbatasan karena tidak menyimpan informasi posisi pola dalam citra. Perhitungan histogram dilakukan pada seluruh area citra, sehingga fitur yang dihasilkan tidak banyak berubah ketika motif bergeser posisi. Akibatnya, susunan dan struktur motif dalam skala besar belum dapat direpresentasikan dengan baik.

3.5 Hasil Ekstraksi Fitur SIFT-BoVW

SIFT menggambarkan bentuk lokal citra lewat arah gradien, lalu Bag of Visual Words meringkas ribuan deskriptor itu menjadi satu histogram 256 angka per citra.

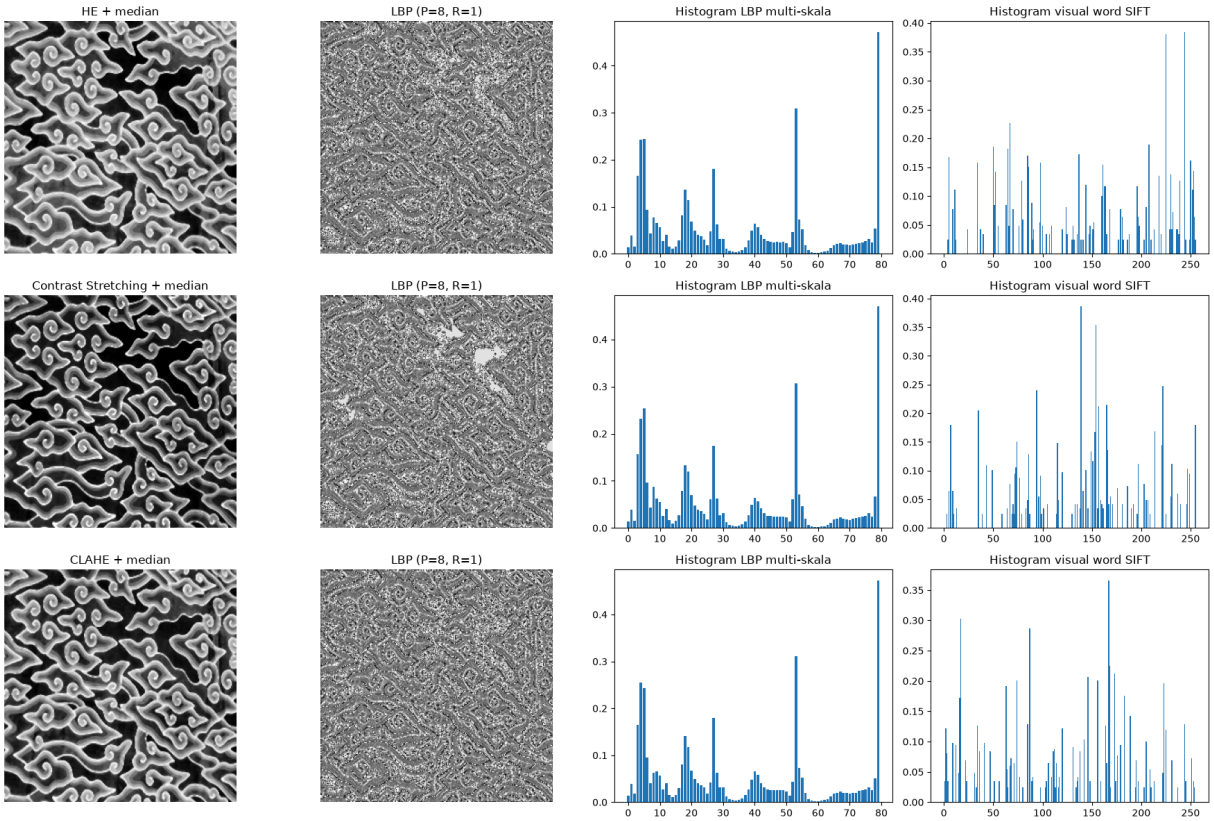
Cara kerjanya:

1. Titik pada grid. Titik diletakkan teratur tiap 8 piksel dengan dua ukuran (8 dan 16). Satu citra 256×256 menghasilkan 1684 titik.
2. Deskriptor SIFT. Area di sekitar tiap titik dibagi menjadi 4×4 sel. Tiap sel menyimpan histogram arah gradien 8 arah, sehingga satu deskriptor berisi 128 angka.
3. RootSIFT. Tiap deskriptor dinormalisasi lalu diakarkan, agar beberapa arah gradien yang sangat kuat tidak mendominasi.
4. Kamus visual word. K-means mengelompokkan deskriptor dari citra latih menjadi 256 kelompok. Tiap pusat kelompok disebut satu visual word.
5. Histogram per citra. Tiap deskriptor diberi label visual word terdekat. Jumlah kemunculan tiap word menjadi histogram 256 angka, yang kemudian dinormalisasi dan diakarkan.

Tabel 3.3 Parameter ekstraksi fitur SIFT-BoVW

Parameter	Nilai di program
Jarak grid	8 piksel
Ukuran titik	8 dan 16
Deskriptor per citra	1684, masing-masing 128 angka
Jumlah visual word	256
Sampel untuk k-means	300 deskriptor acak dari tiap

	citra latih (57,300 deskriptor)
Jumlah fitur akhir	256 per citra



Gambar 3.6 Hasil ekstraksi fitur SIFT-BoVW

Setiap visual word merepresentasikan pola lokal yang sering ditemukan pada data latih, seperti garis lengkung, sudut, dan bidang datar. Histogram visual word digunakan untuk menunjukkan frekuensi kemunculan setiap pola tersebut dalam suatu citra.

Distribusi visual word dapat berbeda pada setiap motif batik. Pada citra kawung, terdapat satu visual word dengan nilai sekitar 0,7. Karena histogram telah dinormalisasi dan kemudian diakarkan, nilai tersebut setara dengan proporsi sekitar 49% deskriptor sebelum proses pengakaran ($0,7^2 \approx 0{,}49$). Hal ini menunjukkan bahwa hampir setengah deskriptor masuk ke dalam satu kelompok pola yang sama, yang kemungkinan mewakili area gelap dengan tekstur relatif rata. Sementara itu, histogram pada motif megamendung memiliki distribusi yang lebih merata, dengan nilai tertinggi sekitar 0,35 sampai 0,40. Kondisi ini sesuai dengan karakteristik

motif megamendung yang memiliki garis awan berlapis, sehingga pola lokal yang dihasilkan lebih beragam dan tersebar ke beberapa visual word.

Berbeda dengan LBP yang telah dibahas pada subbab sebelumnya, histogram SIFT menunjukkan perbedaan yang lebih terlihat pada setiap metode enhancement. Salah satu penyebabnya adalah kamus visual word dibuat secara terpisah untuk setiap metode enhancement. Dengan demikian, visual word pada posisi yang sama dalam histogram belum tentu mewakili pola yang sama, sehingga nilainya tidak dapat dibandingkan secara langsung. Selain itu, deskriptor SIFT dibentuk berdasarkan besar dan arah gradien pada citra. Contrast Stretching cenderung mempertahankan pola gradien karena hanya mengubah skala intensitas secara linear, sedangkan HE dan CLAHE mengubah kontras secara nonlinier yang dapat memengaruhi distribusi gradien dan menghasilkan deskriptor yang berbeda.

Pembentukan kamus visual word hanya menggunakan data latih untuk menghindari kebocoran informasi dari data uji. Proses ini dilakukan dengan mengambil 300 deskriptor secara acak dari setiap citra latih, sehingga terkumpul 57.300 deskriptor yang digunakan dalam proses pengelompokan menggunakan algoritma K-Means. Data uji tidak dilibatkan dalam pembentukan kamus tersebut. Dengan demikian, proses ekstraksi fitur dan pembentukan kamus tidak menggunakan informasi dari data uji yang nantinya digunakan untuk mengevaluasi performa klasifikasi.

Meskipun demikian, pendekatan ini memiliki keterbatasan karena menggunakan ukuran titik yang tetap, yaitu 8 dan 16 piksel. Pada SIFT standar, skala fitur ditentukan secara otomatis melalui proses deteksi titik penting, sedangkan dense SIFT menggunakan titik-titik dengan ukuran yang telah ditentukan. Akibatnya, metode ini belum sepenuhnya mampu menangani perubahan skala. Foto motif batik yang sama tetapi diambil dari jarak berbeda dapat menghasilkan distribusi visual word yang berbeda, sehingga berpotensi memengaruhi hasil klasifikasi.

3.6 Perbandingan Hasil Klasifikasi

SIFT lebih tinggi daripada LBP pada cross-validation di ketiga enhancement, tetapi pada data uji keduanya setara. Semua kombinasi berada di kisaran 0.52–0.70, sekitar tiga kali tebakan acak (0.20).

Cara pengujian:

1. 239 citra dibagi menjadi 191 citra latih dan 48 citra uji (80/20), dengan proporsi kelas yang sama di keduanya.
2. Pengklasifikasi: SVM, dengan fitur distandarkan lebih dulu.
3. Parameter SVM (kernel, C, gamma) dipilih lewat 5-fold cross-validation pada data latih saja.
4. Akurasi akhir dihitung pada 48 citra uji, yang tidak pernah dipakai saat memilih parameter.

Enhancement	**Fitur**	**Jumlah fitur**	**Akurasi CV (latih)**	**Akurasi uji**	**Macro F1 uji**	**Parameter SVM terbaik**
HE	LBP	80	0.628	0.562	0.571	RBF, C = 100, gamma = 0.0001
HE	SIFT	256	0.665	0.521	0.510	Linear, C = 0.01
Contrast Stretching	LBP	80	0.618	0.625	0.637	Linear, C = 0.1
Contrast Stretching	SIFT	256	0.691	0.625	0.627	RBF, C = 10, gamma = scale
CLAHE	LBP	80	0.633	0.625	0.635	RBF, C = 10, gamma = 0.001
CLAHE	SIFT	256	0.697	0.604	0.589	RBF, C = 10, gamma = 0.001

LBP berbanding SIFT. Pada cross-validation, SIFT unggul 0.04–0.07 di setiap enhancement. Pada data uji, SIFT sama atau sedikit di bawah LBP. Data uji hanya 48 citra, jadi

satu citra bernilai sekitar 2 poin, dan selisih di data uji hanya setara 1–2 citra. Akurasi CV dihitung dari 191 citra, sehingga lebih stabil sebagai pembanding.

Antar enhancement. Akurasi LBP hampir tidak berubah (0.618–0.633 pada CV), sesuai sifatnya yang tidak terpengaruh perubahan kontras. Akurasi SIFT paling rendah pada HE (0.665) dan paling tinggi pada CLAHE (0.697). HE juga memberi akurasi uji terendah untuk kedua fitur. Jadi metode yang paling banyak mengubah citra (MSE tertinggi) tidak memberi fitur yang lebih baik.

Kombinasi terbaik. Menurut CV, CLAHE dengan SIFT (0.697). Menurut data uji, tiga kombinasi sama di 0.625: Contrast Stretching dengan LBP, Contrast Stretching dengan SIFT, dan CLAHE dengan LBP.

Akurasi per kelas (recall) dari cross-validation pada data latih:

Kombinasi	**Ceplok**	**Kawung**	**Megamendung**	**Parang**	**Tambal**
HE + LBP	0.50	0.47	0.86	0.57	0.72
HE + SIFT	0.55	0.67	0.86	0.62	0.62
Contrast Stretching + LBP	0.45	0.47	0.86	0.62	0.68
Contrast Stretching + SIFT	0.58	0.61	0.78	0.82	0.65
CLAHE + LBP	0.45	0.44	0.86	0.57	0.82
CLAHE + SIFT	0.66	0.64	0.86	0.68	0.65

1. Megamendung paling mudah dikenali (0.78–0.86 di semua kombinasi). Garis awan yang melengkung dan berlapis tidak dimiliki kelas lain.

2. SIFT lebih baik untuk kawung dan ceplok. Recall kawung naik dari 0.44–0.47 (LBP) menjadi 0.61–0.67 (SIFT), dan ceplok dari 0.45–0.50 menjadi 0.55–0.66. Kedua motif ini ditentukan oleh bentuk (elips, bintang, kotak), yang lebih terekam oleh arah gradien.
3. LBP lebih baik untuk tambal (0.68–0.82 berbanding 0.62–0.65). Tambal berisi banyak isian halus yang berbeda-beda, sehingga statistik tekstur lebih membantu daripada bentuk.
4. Pasangan yang sering tertukar berbeda untuk tiap fitur. Dengan LBP, ceplok paling sering ditebak sebagai tambal (12–16 dari 38 citra ceplok). Dengan SIFT, ceplok dan kawung saling tertukar (6–9 citra ke tiap arah). Setidaknya satu citra di kelas ceplok memang berjudul "Ceplok Kawung Sawut", jadi kedua kelas ini berbagi unsur motif.
5. SIFT lebih mudah overfitting. Selisih akurasi CV dan uji pada SIFT mencapai 0.14 (HE) dan 0.09 (CLAHE). Dengan 256 fitur dan 191 citra latih, model lebih mudah menghafal data latih.

BAB IV
KESIMPULAN

Berdasarkan hasil pengolahan citra dan pengujian klasifikasi motif batik, metode CLAHE menghasilkan nilai MSE terendah sebesar 965,67 dan PSNR tertinggi sebesar 19,20 dB. Sementara itu, *Contrast Stretching* memperoleh PSNR sebesar 19,16 dB, sedangkan *Histogram Equalization* menghasilkan MSE tertinggi sebesar 2332,93 dan PSNR terendah sebesar 15,57 dB. Hasil tersebut menunjukkan bahwa CLAHE menghasilkan perubahan nilai piksel yang relatif lebih kecil terhadap citra acuan berdasarkan kedua metrik evaluasi yang digunakan.

Penerapan *median filtering* dengan kernel 3 × 3 bertujuan mengurangi gangguan berupa bintik pada citra dengan tetap mempertahankan batas pola motif. Proses filtering ini turut diperhitungkan dalam evaluasi MSE dan PSNR karena pengukuran dilakukan terhadap citra setelah melalui tahap enhancement dan filtering.

Pada tahap ekstraksi fitur dan klasifikasi, SIFT dengan pendekatan *Bag of Visual Words* (BoVW) menunjukkan akurasi *cross-validation* yang cenderung lebih tinggi dibandingkan LBP multi-skala. Namun, hasil pada data uji menunjukkan bahwa keunggulan tersebut tidak selalu konsisten. Pemilihan metode enhancement juga memberikan pengaruh yang berbeda terhadap hasil klasifikasi. LBP multi-skala menunjukkan performa yang relatif stabil pada ketiga metode enhancement, sedangkan performa SIFT-BoVW bervariasi sesuai dengan metode enhancement yang digunakan.

Hasil pengujian per kelas menunjukkan bahwa motif Megamendung relatif lebih mudah dikenali oleh model. SIFT-BoVW memberikan hasil yang lebih baik pada motif dengan pola yang jelas, seperti Kawung dan Ceplok, sedangkan LBP menunjukkan hasil yang lebih baik pada motif Tambal. Hal ini menunjukkan bahwa efektivitas metode ekstraksi fitur dapat dipengaruhi oleh karakteristik visual setiap motif batik.

Praktikum ini memiliki beberapa keterbatasan, yaitu penggunaan hanya lima dari 20 kelas pada dataset asli, jumlah data uji yang terbatas sebanyak 48 citra, serta penggunaan citra *grayscale* berukuran 256 × 256 piksel yang tidak memanfaatkan informasi warna. Selain itu, MSE dan PSNR hanya mengukur perbedaan nilai piksel terhadap citra acuan sehingga belum sepenuhnya menggambarkan kualitas visual hasil enhancement.

Secara keseluruhan, praktikum ini menunjukkan bahwa metode enhancement dan ekstraksi fitur memiliki peran dalam proses klasifikasi motif batik. CLAHE memberikan hasil terbaik berdasarkan nilai MSE dan PSNR, sedangkan SIFT-BoVW menunjukkan potensi yang baik dalam klasifikasi. Meskipun demikian, metode dengan hasil terbaik bergantung pada metrik evaluasi, karakteristik motif, dan kombinasi tahapan pengolahan citra yang digunakan.

DAFTAR PUSTAKA

Ijaz, U. (2023). Quantitative analysis of image enhancement algorithms for diverse applications. *International Journal of Innovations in Science & Technology, 5*(4), 694–707.

Sidik, Firmansyah, & Anwar, S. (2019). Perbaikan citra malam (tidak infrared) dengan metode histogram equalization dan contrast stretching. *Jurnal Ilmu Pengetahuan dan Teknologi Komputer, 4*(2), 203–210.

Supriyanti, R., Priyono, S. A., Murdyantoro, E., & Widodo, H. B. (2017). Histogram equalization for improving quality of low-resolution ultrasonography images. *TELKOMNIKA (Telecommunication Computing Electronics and Control), 15*(3), 1397–1408. https://doi.org/10.12928/telkomnika.v15i3.5537

LAMPIRAN

1. Unduh dataset Indonesian Batik Motifs
2. Kode program ada di github.com/PeonyNeroli/Comvis14.